

三、数据导入

1. 简单文本

1) LangChain 加载文档

A. 加载单个文件示例

```
from langchain_community.document_loaders import TextLoader
loader = TextLoader("文件路径")
documents = loader.load()
print(documents)
```

说明：“文件路径”可以是绝对路径或相对路径，返回的 documents 是一个 langchain_core.documents.base.Document 对象的 List, 文档内容存在 Document 对象的 page_content 属性里

B. 通过 os 获取当前 py 文件的运行路径（不适用于 Jupyter）

```
import os
# 获取当前脚本文件所在的目录
script_dir = os.path.dirname(__file__)
# 结合相对路径构建完整路径
file_dir = os.path.join(script_dir, '相对路径')
```

C. 直接创建 Document 对象

```
from langchain_core.documents import Document
documents = [
    Document(
        page_content="悟空是大师兄.",
        metadata={"source": "师徒四人.txt"},
    ),
    Document(
        page_content="八戒是二师兄.",
        metadata={"source": "师徒四人.txt"},
    ),
]
```

D. 使用 DirectoryLoader 加载目录

```

from langchain_community.document_loaders import DirectoryLoader
loader = DirectoryLoader(path='指定目录')
docs = loader.load()
print(f"文档数: {len(docs)}") # 输出文档总数

```

说明: 直接执行上述代码一般会报错: `ModuleNotFoundError: No module named 'unstructured'`, 因为 `DirectoryLoader` 默认使用了基于 `unstructured` 库的加载器 (如 `UnstructuredFileLoader`), 而环境中没有安装 `unstructured` 包。

① 如果仅加载纯文本文档, 可以通过 `loader_cls` 指定加载器为 `TextLoader`

② 如果目录中还有其它非文本文件, 可以通过 `glob` 参数指定文件类型

③ 如果还需要加载子目录中的文件, 可以通过设置 `recursive` 参数为 `True`

④ 非文本文件稍后讲解

⑤ 另有 `use_multithreading` 参数设置是否使用多线程加载 (默认 `False`)、`show_progress` 参数设置是否显示加载进程 (默认 `False`)、`silent_errors` 参数设置是否忽略错误 (默认 `False`)

2) LlamaIndex 加载文档

A. 使用 SimpleDirectoryReader 加载目录

```

from llama_index.core import SimpleDirectoryReader
dir_reader = SimpleDirectoryReader(input_dir="指定目录")
documents = dir_reader.load_data()

```

说明: 返回的 `documents` 是一个 `llama_index.core.schema.Document` 对象的 `List`, 文档内容存在 `Document` 对象的 `text` 属性里, 其它属性相对较多。另外, 与 `Langchain` 不同, 各种格式文件都能加载成功, 但并不都能提取出文字信息。

B. 直接创建 Document 对象

```

from llama_index.core import Document
# 创建多个文档对象, 并为其添加元数据
docs = [
    Document(
        text="一个充满……",
        metadata={
            "filename": "火照深渊场景.md",
            "category": "游戏场景",
            "file_path": "/data/黑悟空/火照深渊场景.md",

```

```

        "author": "GameScience",
        "creation_date": "2024-11-20",
        "last_modified_date": "2024-11-21",
        "file_type": "markdown",
        "word_count": 28,
    },
),
Document(
    text="一片高……",
    metadata={
        "filename": "风起长空场景.md",
        "category": "游戏场景",
        "file_path": "/data/黑悟空/风起长空场景.md",
        "author": "GameScience",
        "creation_date": "2024-11-20",
        "last_modified_date": "2024-11-21",
        "file_type": "markdown",
        "word_count": 28,
    },
)]

# 打印每个文档的元数据
for doc in docs:
    print(f"Metadata for {doc.metadata['filename']}:")
    for key, value in doc.metadata.items():
        print(f"  {key}: {value}")
    print("-" * 40)

```

C. 更多 SimpleDirectoryReader 用法

仅加载某一个特定文件

```

dir_reader = SimpleDirectoryReader(input_files=["黑神话/设定.txt"])
documents = dir_reader.load_data()
print(f"文档数量: {len(documents)}")

```

说明: SimpleDirectoryReader 还有以下可选参数

- ① exclude: 需要排除的文件列表
- ② exclude_hidden (默认 True): 是否排除隐藏的文件
- ③ exclude_empty (默认 False): 是否排除空文件

- ④ num_files_limit: 文件数量限制 (小于该参数值)
- ⑤ recursive (默认 False) : 递归加载
- ⑥ required_exts: 指定加载文件的扩展名